PROGRAMME DE FORMATION DÉVELOPPEUR EN INTELLIGENCE ARTIFICIELLE OU CERTIFICATION PROFESSIONNELLE DÉVELOPPEUR EN INTELLIGENCE ARTIFICIELLE ET DATA SCIENCE RNCP36581

Bloc E6.2 - Développer un modèle prédictif d'une solution I.A
Bloc E6.4 - Gérer les activités/tâches du développement d'une solution I.A

Cahier des Charges de la MSPR « Développement d'un modèle d'apprentissage répondant au besoin d'une solution IA à partir des éléments de contextes fournis »

COMPÉTENCES ÉVALUÉES :

Certification professionnelle Développeur en intelligence artificielle et data science RNCP36581 :

- Générer des données d'entrée, récolter et adapter les types de données traitées nécessaires au modèle d'apprentissage en utilisant des approches et des outils adaptés.
- Paramétrer un environnement de codage (Framework) adéquat pour développer le modèle d'apprentissage.
- Coder le modèle d'apprentissage choisi (réseau de neurones, boosting, forêt aléatoire, arbre de décision, etc) en maitrisant les différentes architectures dans un environnement de développement.
- Réaliser et paramétrer une procédure d'entrainement adéquate d'un modèle d'apprentissage : supervisé, semi-supervisé, non supervisé, en sélectionnant des données d'apprentissages les plus adéquats aux besoins d'analyse.
- Réaliser une phase de test en choisissant une méthode appropriée afin d'analyser la performance du modèle de données.
- Ajuster l'apprentissage du modèle (entraînement) à partir du taux d'apprentissage et des résultats obtenus.
- Mettre en œuvre une méthodologie adaptée de réalisation du projet, afin de garantir le déploiement du projet en collaboration avec les équipes projet dans les délais et dans un environnement agile.
- Rendre compte de l'avancement du projet aux personnes en lien avec le projet grâce aux canaux de communication adéquat et adapté afin de permettre à tout public d'accéder librement et facilement au numérique (public cible, collaborateurs interne, ...) / Rédiger des rapports d'activité et de reste à faire, éventuellement en anglais / Recommander des actions.
- Contribuer ou animer des réunions de travail avec les équipes projets afin de faire évoluer l'avancée du projet, possiblement en anglais.
- Auto-contrôler ses actions et productions au regard du cahier des charges afin de garantir leurs cohérences.
- Définir et mettre en place un système de veille permettant de collecter, classifier et analyser l'information afin d'améliorer la prise de décisions techniques.
- Améliorer le potentiel de développement et/ou d'exploitation des solutions IA en exploitant les informations recueillies par le système de veille : Technologiques , Réglementaires, Sécurité informatique.

Programme de formation Développeur en intelligence artificielle :

- Analyser le besoin d'application d'un commanditaire intégrant un service d'intelligence artificielle, en rédigeant les spécifications fonctionnelles et en le modélisant, dans le respect des standards d'utilisabilité et d'accessibilité, afin d'établir avec précision les objectifs de développement correspondant au besoin et à la faisabilité technique.
- Concevoir le cadre technique d'une application intégrant un service d'intelligence artificielle, à partir de l'analyse du besoin, en spécifiant l'architecture technique et applicative et en préconisant les outils et méthodes de développement, pour permettre le développement du projet.
- Coordonner la réalisation technique d'une application d'intelligence artificielle en s'intégrant dans une conduite agile de projet et un contexte MLOps et en facilitant les temps de collaboration dans le but d'atteindre les objectifs de production et de qualité.
- Développer les composants techniques et les interfaces d'une application en utilisant les outils et langages de programmation adaptés et en respectant les spécifications fonctionnelles et techniques, les standards et normes d'accessibilité, de sécurité et de gestion des données en vigueur dans le but de répondre aux besoins fonctionnels identifiés.

- Automatiser les phases de tests du code source lors du versionnement des sources à l'aide d'un outil d'intégration continue de manière à garantir la qualité technique des réalisations.
- Créer un processus de livraison continue d'une application en s'appuyant sur une chaîne d'intégration continue et en paramétrant les outils d'automatisation et les environnements de test afin de permettre une restitution optimale de l'application.
- Surveiller une application d'intelligence artificielle, en mobilisant des techniques de monitorage et de journalisation, dans le respect des normes de gestion des données personnelles en vigueur, afin d'alimenter la feedback loop dans une approche MLOps, et de permettre la détection automatique d'incidents.
- Résoudre les incidents techniques en apportant les modifications nécessaires au code de l'application et en documentant les solutions pour en garantir le fonctionnement opérationnel.

PHASE 1 : PRÉPARATION DE CETTE MISE EN SITUATION PROFESSIONNELLE RECONSTITUÉE

- **Durée de préparation** : 29 heures
- **Mise en œuvre** : Travail d'équipe constituée de 4 apprenants (5 maximum si groupe impair)

PHASE 2 : PRÉSENTATION ORALE COLLECTIVE + ENTRETIEN COLLECTIF

- **Objectif** : mettre en avant et démontrer que les compétences visées par ce bloc sont bien acquises.
- **Moyen** : L'équipe utilise un support de présentation
- **Durée totale par groupe** : 50 mn se décomposant comme suit :
  - 20 mn de soutenance orale par l'équipe.
  - 30 mn d'entretien collectif avec le jury (questionnement complémentaire).
- **Jury d'évaluation** : 2 personnes (binôme d'évaluateurs) par jury – Ces évaluateurs ne sont pas intervenus durant la période de formation et ne connaissent pas les apprenants à évaluer.

I – CONTEXTE

ObRail Europe est un observatoire indépendant spécialisé dans le ferroviaire et la mobilité durable. Créée en 2018, l'organisation s'est imposée comme un acteur de référence dans l'analyse des flux ferroviaires européens et la promotion du transport bas-carbone.

Sa mission principale est de :

- Collecter et analyser les données relatives aux dessertes ferroviaires en Europe.
- Évaluer l'impact environnemental des modes de transport longue distance.
- Produire des études comparatives destinées aux décideurs politiques et aux opérateurs ferroviaires.
- Accompagner la transition écologique en favorisant l'usage du train comme alternative à l'avion sur les trajets intra-européens.

ObRail travaille en partenariat avec :

- Les institutions européennes (Commission européenne, Parlement européen) pour alimenter les politiques publiques.
- Des ONG environnementales telles que Transport & Environnement ou Back-on-Track afin de renforcer l'argumentaire écologique.
- Les opérateurs ferroviaires (SNCF, ÖBB Nightjet, DB, Trenitalia) qui souhaitent valoriser leurs services de trains de jour et de nuit.

L'organisation s'inscrit dans les grandes stratégies européennes :

- Le **Green Deal européen**, qui vise la neutralité carbone à l'horizon 2050.
- Le programme TEN-T (Trans-European Transport Network), qui a pour objectif de renforcer l'intégration et la compétitivité du réseau ferroviaire en Europe.

ObRail souhaite comparer la contribution des trains de jour et des trains de nuit au maillage ferroviaire européen. L'objectif est de **mesurer leur rôle dans la construction d'une mobilité durable** et d'évaluer leur potentiel en tant qu'alternative crédible à l'avion sur les trajets intra-européens.

Pour cela, il est nécessaire de constituer un référentiel de données fiable et harmonisé qui servira :

- à l'analyse de la couverture ferroviaire,
- à l'entraînement de modèles d'IA,
- et au développement d'un service applicatif destiné aux partenaires.

L'étude préliminaire réalisée par ObRail Europe a mis en évidence plusieurs contraintes majeures auxquelles le projet devra répondre :

1. Dispersion des données

Les informations relatives aux dessertes ferroviaires européennes sont publiées par une multitude d'acteurs (opérateurs nationaux, plateformes open data, organismes statistiques). Chaque source utilise son propre format (CSV, flux GTFS, API, fichiers Excel, HTML scraping), ce qui rend leur intégration particulièrement complexe.

2. Qualité hétérogène des jeux de données

Les données collectées présentent des problèmes de complétude et de fiabilité : doublons, informations manquantes (codes de gares, fuseaux horaires, identifiants de lignes), incohérences dans les unités ou les formats de date/heure. Ces particularités doivent être traitées en amont afin de garantir la robustesse des analyses futures.

3. Absence de standardisation transfrontalière

Il n'existe pas de référentiel commun permettant de comparer facilement les dessertes ferroviaires entre pays européens. Chaque opérateur applique ses propres conventions (nomenclature des gares, structure des horaires, indicateurs de performance), ce qui empêche une comparaison homogène des données.

4. Exigences réglementaires

Le projet doit se conformer au Règlement Général sur la Protection des Données (RGPD). Même si aucune donnée personnelle n'est traitée, les règles de sécurité, de documentation et de transparence dans la gestion des jeux de données doivent être respectées.

5. Contraintes temporelles

ObRail doit livrer une première version exploitable de l'entrepôt de données aux institutions européennes avant la fin de l'année. Cette échéance impose un processus ETL fiable, automatisé et reproductible, permettant de garantir la mise à jour régulière des données.

II – CAHIER DES CHARGES

ObRail souhaite développer un ensemble de modèles capables de répondre plusieurs enjeux métiers clés :

- Anticiper la demande en mobilité ferroviaire : prédire la fréquentation future de certaines liaisons.
- Évaluer l'impact environnemental futur : estimer les émissions de CO2, en fonction de scénarios de développement du réseau.
- Détecter les zones de sous-desserte ou fragiles : classification des relations présentant un risque stratégique.
- Prévision de saturation ou de congestion sur certaines liaisons
- Identification automatique des lignes candidates à la substitution avion par train
- Identifier les lignes prioritaires ou à fort potentiel de croissance.

ObRail souhaite à minima l'exploration d'un de ses enjeux et permet le choix d'un axe seulement ou d'en explorer plusieurs, tant que le choix est expliqué, réaliste et cohérent avec les données. L'équipe projet est libre de proposer à ObRail d'autres enjeux pertinents si celle-ci dispose des données.

1. **Contraintes techniques et méthodologiques**

ObRail demande la comparaison des services d'intelligence artificielle, cette étude préalable doit permettre le choix et la justification des services et modèles.
Plusieurs fournisseurs peuvent proposer des services, mais ObRail accepte toute nouvelle proposition : Azure Machine Learning, Amazon SageMaker, Google Cloud AutoML, etc.
Le modèle développé devra :

- Être reproductible, justifié et documenté ;
- Respecter les bonnes pratiques de préparation, séparation et évaluation des données ;
- Suivre un workflow standard : exploration, préparation, modèles candidats, évaluation, sélection, sauvegarde ;
- Être sauvegardé dans un format compatible avec une future intégration API (pickle, joblib, etc.) ;
- Être accompagné d'un pipeline de prédiction minimal reproductible.

2.. **Contraintes réglementaires**

ObRail souhaite le respect des principes éthiques et RGPD : transparence, minimisation, documentation.

ObRail – demande une explication dans le choix des solutions- et encourage l'usage de solutions open source mais accepte aussi des standards du marché, (scikit-learn, XGBoost, TensorFlow/Keras, etc.).
De la même façon, ObRail exige une justification des choix algorithmiques et des métriques. Le choix de la famille (égression, classification, partitionnement de données, réduction de dimensions) et des modèles (réseau de neurones, boosting, forêt aléatoire, arbre de décision, etc) devra être expliqué et comparé.

3. **Utilisateurs cibles**

- Équipe Data Science interne d'ObRail : entraînement et optimisation continue du modèle.
- Institutions et décideurs européens : exploitation des prédictions pour orienter leurs choix stratégiques.
- ONG et opérateurs ferroviaires : appui à la communication et à la planification.

III. LES BESOINS EXPRIMÉS PAR OBRAIL

Pour garantir la mise en production d'une solution fiable, maintenable et conforme aux attentes du cahier des charges, ObRail Europe exige que l'équipe projet réponde à un ensemble de besoins fonctionnels, techniques et réglementaires. Ces besoins définissent précisément les éléments à concevoir, développer, tester et documenter.

1. **Analyse exploratoire et préparation des données**

- En vous basant sur vos derniers travaux, vous pouvez réutiliser et/ou récolter et/ou générer des données (trajets, horaires, type de train, distance, émissions CO_2...)
- Identifier les valeurs aberrantes, données manquantes, incohérences.
- Effectuer les transformations nécessaires : encodage, normalisation/standardisation, feature engineering approprié.
- Construire les ensembles train / validation / test.
- Livrable attendu : notebook ou script d'analyse et tableau des variables retenues.

2. **Mise en place de l'environnement d'apprentissage**

- Configurer l'environnement de développement (par exemple : Python/scikit-learn, TensorFlow, PyTorch...).
- Documenter les dépendances et paramètres.
- Livrable attendu : dossier projet structuré et fichier requirements.txt.

3. **Développement de plusieurs modèles candidats**

- tester plusieurs modèles algorithmiques et par exemple : régression (linéaire ou regularisée), RandomForest, modèles de boosting (XGBoost, LightGBM) et Réseaux neuronaux simples (MLP).
- justifier les choix retenus et expliquer pourquoi certains modèles sont pertinents ou non pour les données.
- Livrable attendu : scripts entraînement et tableau comparatif des modèles.

4. **Entraînement, optimisation et validation**

- Mettre en œuvre une procédure d'entraînement adaptée : recherche d'hyperparamètres (GridSearch, RandomSearch...), cross-validation.
- Évaluer chaque modèle avec les métriques pertinentes selon le type de tâche.
- Sélectionner le modèle final.
- Documenter les performances et limites.
- Livrable attendu : rapport d'évaluation + visualisations.

5. **API d'exposition**

- Fournir un prototype d'API REST (FastAPI / Flask) exposant une route /predict utilisant le modèle sauvegardé.
- Intégrer l'API dans l'application ou à défaut documenter cette intégration
- Identifier les métriques qui seraient pertinentes pour le monitoring du modèle dans le cadre de l'application en production

6. **Benchmark des services d'I.A existants**

- Comparer les capacités de services IA préexistants, et par exemple : AWS Sagemaker, Google AutoML, Azure Machine Learning, HuggingFace AutoTrain...
- Évaluer : prix, contraintes, performances potentielles, facilité d'intégration.
- Justifier le choix d'un modèle interne ou non
- Livrable attendu : tableau comparatif et recommandations.

7. **Sauvegarde, documentation et reproductibilité**

- Sauvegarder le modèle final (pickle/joblib).
- Créer un script predict.py simulant la future intégration API.
- Documenter la procédure de ré-entraînement.
- Livrable attendu : modèle sauvegardé et script de prédiction, ansi que la documentation associée.

8. **Veille, justification et communication projet**

- Mener une veille technique sur les algorithmes et services IA.
- Synthétiser les risques, limites et biais.
- Participer à la communication projet (réunions, reporting…).
- Livrable attendu : section "veille et recommandations" dans le rapport et synthèse.

9. **Rapport technique final + support de soutenance**

- Structurer un rapport clair et exploitable : données, architecture IA, méthodologie, résultats, limites, plan d'amélioration.
- Préparer un support de soutenance professionnel.
- Livrables attendus : rapport technique complet et support de soutenance

IV- LIVRABLES ATTENDUS

À l'issue de la mission, ObRail Europe attend de l'équipe projet la remise d'un ensemble de livrables **exécutables, documentés et directement exploitables**.

Ces livrables doivent démontrer la capacité de l'équipe à **industrialiser, déployer, tester, superviser** et maintenir une solution applicative intégrant des composants d'intelligence artificielle.

L'ensemble des livrables doit pouvoir être évalué **sans intervention extérieure**, et l'application doit être exécutable sur un environnement standard via les fichiers fournis.

Il conviendra de répondre à l'ensemble des besoins exprimés par ObRail dans les livrables :

1. Notebook ou script d'analyse et tableau des variables retenues.
2. Dossier projet structuré et fichier requirements.txt.
3. Scripts entraînement et tableau comparatif des modèles.
4. Rapport d'évaluation + visualisations.
5. Tableau comparatif et recommandations.
6. Modèle sauvegardé et script de prédiction, ainsi que la documentation associée.
7. Section "veille et recommandations" dans le rapport et synthèse.
8. Rapport technique complet
9. Support de soutenance

En complément des livrables techniques, l'équipe projet devra préparer un support de présentation destiné à la soutenance finale devant le client (public technique). Ce support devra synthétiser les principaux éléments du travail réalisé : démarche suivie, difficultés rencontrées, solutions mises en place, résultats obtenus et perspectives.

Il est important de souligner que l'évaluation de cette MSPR repose sur **la combinaison des trois éléments suivants :**

- la qualité du **travail réalisé** au cours du projet,
- la pertinence et l'exhaustivité des **livrables remis** (scripts, modèles, base de données, API, documentation),
- et la capacité de l'équipe à **présenter, justifier et valoriser** ce travail lors de la **soutenance orale.**

Les équipes devront donc s'assurer que la soutenance reflète bien <u>l'ensemble des compétences attendues</u>, en démontrant à la fois la maîtrise technique et la capacité à communiquer efficacement auprès d'un client professionnel.

V. RESSOURCES FOURNIES

Afin de permettre la réalisation méthodique et rigoureuse de cette mise en situation professionnelle, **ObRail Europe met à disposition de l'équipe projet un ensemble de ressources techniques, documentaires et méthodologiques**. Ces ressources constituent un socle commun, mais n'exonèrent en aucun cas l'équipe **de mener une veille autonome et d'opérer des choix argumentés** conformément au cahier des charges.

1. Données mises à disposition

L'équipe dispose :

- des données harmonisées issues du processus ETL déjà développé, comprenant notamment : trajets, types de trains, horaires, distances, facteurs d'émission, fréquences hebdomadaires et indicateurs dérivés ;
- d'un échantillon de données destiné aux tests rapides des scripts de préparation ;
- le cas échéant, de métadonnées issues de sources ouvertes précédemment mobilisées (Back-on-Track, portails GTFS, Eurostat, ADEME).

L'utilisation de sources complémentaires est autorisée par ObRail sous réserve de respecter le cadre réglementaire et de conserver la traçabilité des données.

2. Environnements de développement

ObRail propose l'usage des environnements suivants, couramment utilisés dans les projets de data science :

- Jupyter Notebook / JupyterLab, pour l'analyse exploratoire et le prototypage (https://jupyter.org) ;
- Visual Studio Code, muni des extensions Python, Jupyter et Git (https://code.visualstudio.com) ;
- PyCharm Community Edition, pour le développement structuré (https://www.jetbrains.com/pycharm) ;
- Anaconda ou Miniconda, pour la gestion d'environnements isolés (https://www.anaconda.com).

Ces outils permettent d'assurer une organisation claire du code, une reproductibilité satisfaisante et une collaboration facilitée – il s'agit d'exemples et ne sont en aucun cas un choix, une obligation ou une demande d'ObRail.

3. Langages, bibliothèques et frameworks pour le développement du modèle

Le développement est a priori attendu majoritairement en Python, langage de référence dans le domaine de l'apprentissage automatique. Les bibliothèques suivantes sont proposées :

- NumPy – calcul numérique (https://numpy.org)
- pandas – manipulation de données tabulaires (https://pandas.pydata.org)
- scikit-learn – algorithmes d'apprentissage standards et outils d'évaluation (https://scikit-learn.org)
- XGBoost – algorithmes de gradient boosting performants (https://xgboost.readthedocs.io)
- LightGBM – alternative optimisée de boosting (https://lightgbm.readthedocs.io)
- TensorFlow/Keras ou PyTorch – architectures neuronales si nécessaire (https://www.tensorflow.org, https://pytorch.org)

Ces frameworks permettent de couvrir l'ensemble des besoins du projet : modélisation, validation, optimisation, interprétation et export du modèle.

4. Ressources pour le benchmark des services d'intelligence artificielle

Dans le cadre du benchmark des services IA, l'équipe projet doit analyser au moins trois services différents, elle peut s'appuyer par exemple sur :

- Google Vertex AI / AutoML Tables – https://cloud.google.com/vertex-ai
- Azure Machine Learning Studio – https://azure.microsoft.com/services/machine-learning
- AWS SageMaker (AutoPilot / Canvas) – https://aws.amazon.com/sagemaker
- HuggingFace AutoTrain – https://huggingface.co/autotrain
- IBM Watson Studio AutoAI – https://www.ibm.com/cloud/watson-studio

La comparaison doit porter sur : capacités techniques, transparence, coûts, contraintes, explicabilité, facilité d'intégration et pertinence pour des données ferroviaires.

5. **Ressources pour l'évaluation, la visualisation et l'analyse des résultats**

Les outils suivants sont recommandés pour l'analyse statistique et la production de visualisations de qualité :

- Matplotlib – visualisation de base (https://matplotlib.org)
- Seaborn – visualisation statistique (https://seaborn.pydata.org)
- Plotly – visualisation interactive (https://plotly.com/python)
- SciPy – analyses statistiques et tests (https://scipy.org)

Pour la création d'un tableau de bord exploratoire (optionnel) :

- Streamlit – https://streamlit.io
- Dash (Plotly) – https://dash.plotly.com

6. **Ressources relatives à la reproductibilité et aux bonnes pratiques**

Bien qu'ObRail n'impose pas un pipeline MLOps complet, les outils suivants facilitent la reproductibilité de l'apprentissage :

- pip / requirements.txt – gestion des dépendances ;
- virtualenv ou conda – isolation des environnements ;
- joblib ou pickle – sauvegarde des modèles (https://joblib.readthedocs.io) ;
- Makefile – automatisation simple des scripts d'entraînement (optionnel).

L'équipe doit veiller à respecter les principes fondamentaux de reproductibilité : fixation des graines aléatoires, documentation des étapes, structuration cohérente du projet.

7. **Ressources réglementaires, éthiques et institutionnelles**

L'équipe projet doit tenir compte des recommandations européennes et françaises en matière de développement responsable :

- Ressources bonnes pratiques IA :
  - CNIL – Intelligence artificielle : cadre éthique et bonnes pratiques
  - https://www.cnil.fr/fr/intelligence-artificielle
- Cadre européen de l'IA
  - Ethics Guidelines for Trustworthy AI (Commission européenne)
  - https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai
- Pratiques techniques recommandées
  - Cross-validation (scikit-learn)
  - https://scikit-learn.org/stable/modules/cross_validation.html

Ces ressources constituent un appui essentiel pour la veille et pour la justification des choix méthodologiques.